


[Launch]样式粗排元素化

背景



在创意型广告投放系统中，广告样式最终以style_tuple的形态下发，其中style_tuple由[style_id, tpl_id, comp_ids]叉乘组成，并拥有唯一的tuple_id。随着 [国大规模样式在线召回架构演进](#)，样式的在线投放链路已经从离线组件全叉乘迁移至在线叉乘，极大程度缓解了样式爆炸的问题。然而当前样式粗排仍需要在**离线构建全量style_tuple embedding**，其流程如图所示，这带来如下问题：

- 1. 模型miss率较高：**新样式尤其是通用基础样式上线会导致离线全量叉乘tuple数量不可控，factory_gen服务常态化OOM，样本数量上涨同样带来模型对新样式感知较慢和flink资源上涨，均会导致取ps embedding失败
- 2. PS内存显著增长：**线上样式粗排基线training_ps中，tuple_id embedding约有3.3亿，占PS总内存的23%，长期将指数级别增长
- 3. 投放架构不合理：**样式投放已全端迁移在线叉乘，样式离线叉乘逻辑不应再维护并下掉factory_gen服务

长期我们规划了样式自动化生产投放系统，组件元素的数量预期会有百倍增长，当前模型侧架构已不支持tuple数量的大规模增长

方案

将样式粗排模型的输入从tuple_id下放到样式tuple的元素[style_id, tpl_id, comp_ids]，彻底解决又乘tuple_id爆炸带来的模型侧问题，主要改动如下：[code_diff](#)


样式粗排

粗排晚高峰(user, ad, style)取ps embedding miss率 0.1% -> 0.06% ([link](#))



新样式上线模型侧感知时间：最长3h -> 1min内 (3h全量回灌一次aid，采样1000个aid候选计算闭包又乘tuple)

模型侧



1. viking取ps embedding粒度由tuple_id改为element_id，tuple embedding由elements embedding pooling表示

2. 删除样式粗排数据流，召回数据流新增抽tpl_id特征，样式塔特征合并在一个slot(12111)，粗排和召回共用一条数据流
3. 特征
 - a. 删除'fc_component_id_hash_vec'特征，降低模型对ID的记忆性，提升模型泛化性
 - b. 新增附加素材及相应的类型特征，以debias的形式加入模型，增强样式对素材的感知能力
4. 结构
 - a. 新增预估值与label之间逆序对数量对loss加权，提高模型对困难样本的预估能力
 - b. 删除user ad塔交叉轻量deep化的tf.relu操作，提升模型预估出口embedding特征丰富度
5. 样式召回迁移实时化，实现召回/粗排/CTA合并模型全部走实时化，去除对Feynman的依赖

工程侧

模型侧tuple_id拆解为element_ids后，inspire单req内请求viking去重候选的增长会导致链路时延增长约3ms，有如下优化方案（以下为RM测算结果）：

1. inspire请求viking会透传去重element_ids的索引信息，pb在存储2D索引信息时，会存储在不同的内存地址，需要通过第一维保存的指针对第二维的元素进行寻址。遍历索引信息时由于内存地址不连续，会有cache line miss，将导致额外的访存开销。将element_indices从[batch_size, padding_num]2D回退为1D[batch_size*padding_size]后，索引信息存储在整片连续的内存上，可以有效减少inspire和viking对索引信息的访存开销，**实测时延-1.2ms**
2. inspire单请求内不同aid下tuple候选重复度较高，在去重element_ids的基础上新增一级tuple去重，减少重复计算，**实测时延-2ms**

叠加上述优化后，粗排元素化模型相比基线时延增长降低到0.6ms，长期来看随着inspire扩条数带来的element_id重复度增加，时延增长会逐步降低，最终的serving图核心代码如下：

代码块

```
1  # 1D tuple索引，更彻底的实现计算上的去重
2  title_indices_fc = FeatureColumnDense("title_indices", 1, tf.int64)
3  # 1D element索引/reshape为[batch, 12] 用以构建每个tuple候选索引
4  title_list_indices_fc = FeatureColumnDense("title_list_indices", 12, tf.int64)
5  # padding_size = 12
6  title_indices_vec = title_indices_fc.get_tensor()
7  title_list_indices_vec = title_list_indices_fc.get_tensor()
8
9  # 根据索引取PS相应embedding候选
10 expand_element_embedding = tf.gather(style_vec_bias,
11                                     tf.squeeze(title_list_indices_vec), axis=0)
12 # tuple下element的embedding做sum-pooling操作获取tuple embedding
13 expand_tuple_embedding = tf.reduce_sum(expand_element_embedding, axis=1) #
14 sum-pooling
```

```
13 # 根据tuple_embedding和tuple索引实现batch样式tuple embed候选的还原
14 expand_style_embedding = tf.gather(expand_tuple_embedding,
    tf.squeeze(title_indices_vec, [1]), axis=0)
```

样式召回

召回迁移实时化，晚高峰(user, ad, style)取ps embedding miss率 21% -> 0.1% ([link](#))

模型侧

1. 样式召回基线模型为(user, style)双塔，采用slot=12006 mock aid embedding，ps key有约1.6亿个，实际并不需要，粗排元素化模型删除该slot以节省ps内存

工程侧

1. 三塔模型中，构建召回候选为aid2_style的map，因为召回是双塔模型，所以仅需一个aid作为placeholder，而线上基线采用至多5个aid用于构建候选

实验

实验链接：<https://data.bytedance.net/libra/flight/2566575/edit>

AA：基线

BB：粗排元素化模型

实验时间：2024.04.28 - 2024.05.10（30%流量）

工程指标

资源消耗

1. 30%流量AABB实验creative_ranking资源涨5%，推全预计需 $5\% \times (191+288+91+175)/0.15=248$ 台机器(32C64G)
2. 下线factory_gen离线全量叉乘集群，共占用2台机器（64C256G）
3. 删除样式粗排流式数据流，topic：ad_inspire_batch_instance_style_ies
4. 模型training_ps：640G -> 169G，降低74%；online_ps：154G -> 99G，降低36%

链路时延

以有召回实时化的28038为例

sort_aweme服务延时涨0.6ms

adminx 延时分析深度分析无显著性计算

各端采样率: 1/3(Libra) * [搜索: 1/100 ; GIP: 1/1000 ; IES: 1/1000 ; union: 1/10000]

实验分组	adminx请求数量	adminx平均耗时	targeting平均延时	cypher平均延时	inspire平均延时	predict平均延时	themis平均延时	adminx耗时p99均值	targeting耗时p99均值	cypher耗时p99均值	inspire耗时p99均值	predict耗时p99均值
v1 对照组	194,705	806,766	117,318	93,197	107,999	345,909		892,889	136,649	122,713	125,792	402,209
v2 对照组	+0.578% 195,831	-0.044% 806,414	-0.078% 117,226	-0.085% 93,118	-0.06% 107,935	-0.004% 345,894	0%	-0.023% 892,687	+0.028% 136,687	-0.219% 122,444	-0.018% 125,769	+0.023% 402,300
v3	-0.029% 194,649	+0.048% 807,153	+0.067% 117,396	+0.105% 93,295	+0.508% 108,548	-0.113% 345,517	0%	+0.023% 893,098	+0.188% 136,906	+0.248% 123,018	+0.564% 126,502	-0.073% 401,914
v4	+0.089% 194,879	+0.03% 807,008	-0.069% 117,236	-0.17% 93,039	+0.561% 108,605	-0.039% 345,773	0%	-0.04% 892,529	-0.137% 136,462	-0.531% 122,062	+0.583% 126,525	+0.009% 402,243

sort_aweme服务CPU使用量基本持平

CPU度量深度分析无显著性计算| 计算工具

指标需要分psm看才有意义, 背景参考 参考链接, 数据底表: 参考链接

实验分组	CPU使用量	平均请求CPU使用量	GPU 机器CPU使用量	平均GPU机器CPU使用量	GPU机器GPU使用量	平均GPU机器GPU使用量	流量入口请求总数
v1 对照组	1,842,120,179	155.3	0	0	0	0	11,864,178
v2 对照组	+0.021% 1,842,506,550	-0.007% 155.3	-% 0	-% 0	-% 0	-% 0	+0.028% 11,867,451
v3	+0.025% 1,842,588,218	+0.154% 155.5	-% 0	-% 0	-% 0	-% 0	-0.128% 11,848,939
v4	+0.061% 1,843,243,693	+0.153% 155.5	-% 0	-% 0	-% 0	-% 0	-0.092% 11,853,317

inspire服务时延上涨挤压predict时延quota, 预估成功创意数下降导致send略负向

adminx 广告漏斗深度分析无显著性计算

各端采样率: 1/3(Libra) * [搜索: 1/100 ; GIP: 1/1000 ; IES: 1/1000 ; union: 1/10000]。怎么看工程指标: 参考链接

实验分组	targeting成功请求平均计划数	targeting成功请求平均创意数	cypher平均计划数	cypher成功平均创意数	inspire成功平均创意	predict成功请求平均创意
v1 对照组	3,665	4,358	145.7	145.8	145.8	128
v2 对照组	+0.047% 3,667	+0.095% 4,362	+0.003% 145.7	+0.005% 145.8	+0.005% 145.8	-0.007% 127.9
v3	+0.051% 3,667	+0.029% 4,359	+0.041% 145.8	+0.043% 145.9	+0.043% 145.9	-0.052% 127.9
v4	+0.057% 3,667	+0.118% 4,363	+0.054% 145.8	+0.054% 145.9	+0.054% 145.9	-0.058% 127.9

业务指标

大盘整体

send、show置信负向0.05%（p值2%）

综合报告计算显著性

显著性水平 5%

实验分组	cost	广告主价值	ads_score	白名单ads_score	rank广告主价值	深度ads_score	深度rank广告主价值	send	show	SSR	click	dislike
v1 对照组	996,204,369	903,990,743	1,274,413,643	1,189,572,124	1,197,588,732	1,233,105,354	1,156,280,443	23,255,239,204	20,170,263,553	0.86734	637,034,018	2,595,882
v2 对照组	-0.041% 995,799,116	-0.041% 903,617,025	+0.014% 1,274,592,810	+0.009% 1,189,676,502	+0.008% 1,197,689,219	-0.027% 1,232,770,470	-0.036% 1,155,866,879	+0.027% 23,261,513,536	+0.029% 20,176,181,980	+0.002% 0.86736	+0.003% 637,052,566	+0.196% 2,600,961
v3	+0.007% 996,277,626	+0.114% 905,016,882	+0.013% 1,274,578,242	+0.01% 1,189,694,330	+0.011% 1,197,715,409	+0.043% 1,233,635,822	+0.043% 1,156,772,990	-0.037% 23,246,747,669	-0.042% 20,161,791,766	-0.005% 0.8673	+0.07% 637,478,176	-0.104% 2,593,194
v4	-0.06% 995,609,304	+0.054% 904,474,481	-0.046% 1,273,822,988	-0.043% 1,189,058,071	-0.044% 1,197,063,140	-0.037% 1,232,653,327	-0.033% 1,155,893,479	-0.047% 23,244,313,919	-0.049% 20,160,370,213	-0.002% 0.86732	-0.041% 636,775,202	-0.199% 2,590,719

竞价整体

波动持平

竞价整体深度分析无显著性计算 | 计算工具

实验分组	广告主价值	cost	ads_score	白名单 ads_score	深度转化广告 主价值	深度ads_score	白名单 deep_ads_score	深度rank广告主 价值	send	show	SSR	convert	click	dislike/show
v1 对照组	856,948,806	940,976,603	1,198,125,069	1,116,827,669	716,510,540	1,157,994,859	1,076,697,459	1,084,063,911	20,787,906,079	18,089,535,133	0.8702	110,982,253	609,167,062	0.00012
v2 对照组	-0.055%	-0.044%	+0.008%	+0.002%	-0.023%	-0.042%	-0.052%	-0.052%	+0.031%	+0.033%	+0.002%	+0.187%	+0.006%	+0.202%
	856,480,942	940,563,471	1,198,225,294	1,116,852,908	716,342,836	1,157,509,914	1,076,137,528	1,083,500,765	20,794,418,067	18,095,545,418	0.87021	111,189,984	609,205,741	0.00012
v3	+0.099%	+0.01%	+0.003%	+0.001%	+0.133%	+0.039%	+0.039%	+0.04%	-0.038%	-0.048%	-0.011%	+0.223%	+0.07%	-0.107%
	857,800,260	941,074,203	1,198,157,003	1,116,835,020	717,466,820	1,158,443,159	1,077,121,176	1,084,492,533	20,780,045,893	18,080,792,302	0.8701	111,230,148	609,591,261	0.00012
v4	+0.048%	-0.063%	-0.047%	-0.043%	+0.14%	-0.047%	-0.044%	-0.044%	-0.049%	-0.057%	-0.008%	+0.092%	-0.042%	-0.134%
	857,359,158	940,384,907	1,197,564,873	1,116,342,633	717,510,700	1,157,451,142	1,076,228,902	1,083,583,579	20,777,701,637	18,079,217,253	0.87013	111,084,606	608,911,731	0.00012

分端指标

硬广&生效流量位：波动正向

竞价整体深度分析无显著性计算 | 计算工具

实验分组	广告主价值	cost	ads_score	白名单 ads_score	深度转化广告 主价值	深度 ads_score	白名单 deep_ads_score	深度rank广告主 价值	send	show	SSR	convert	click	dislike/show
v1 对照组	459,570,490	518,907,592	649,958,026	599,627,643	387,334,390	625,235,721	574,905,338	581,321,343	8,178,604,870	7,344,663,186	0.89803	45,929,630	221,910,873	0.00014
v2 对照组	-0.037%	-0.018%	+0.063%	+0.061%	-0.062%	+0.086%	+0.086%	+0.085%	+0.024%	+0.02%	-0.004%	+0.165%	+0.024%	+0.1%
	459,401,581	518,813,258	650,366,793	599,990,499	387,093,004	625,774,006	575,397,712	581,816,624	8,180,573,530	7,346,117,246	0.898	46,005,198	221,964,609	0.00014
v3	+0.085%	+0.029%	-0.031%	-0.037%	+0.085%	+0.061%	+0.062%	+0.061%	+0%	-0.004%	-0.004%	+0.133%	+0.095%	+0.09%
	459,963,013	519,056,982	649,758,091	599,403,865	387,664,212	625,614,513	575,260,287	581,677,522	8,178,615,129	7,344,390,841	0.898	45,990,654	222,121,176	0.00014
v4	+0.269%	+0.036%	+0.104%	+0.113%	+0.336%	+0.171%	+0.187%	+0.183%	-0.015%	-0.02%	-0.005%	+0.159%	+0.066%	+0.023%
	460,805,258	519,092,331	650,631,243	600,304,590	388,635,301	626,304,238	575,977,585	582,385,295	8,177,397,057	7,343,212,418	0.89799	46,002,561	222,057,588	0.00014

冷启动

生效位app_convert<=4 advv波动正向

app_convert数量≤4深度分析无显著性计算 | 计算工具

实验分组	cost	广告主价值	冷启动boost	send	show	click	convert	CTR1	CTR2	平均ectr	ectr_diff校 准	平均 recall_ctr	recall_ctr_diff 校准	平均 sati_ctr	sati_ctr_diff 校准
v1 对照组	398,779,287	328,170,139	4,332,304,922	5,728,603,531	5,150,124,311	156,751,923	12,225,265	0.02736	0.03044	0.02836	0.03643	0.02788	-0.06118	0.02373	0.01417
v2 对照组	-0.105%	-0.02%	+0.007%	+0.017%	+0.02%	-0.03%	+0.109%	-0.047%	-0.049%	-0.04%	+0.213%	-0.066%	+0.238%	-0.052%	+0.331%
	398,360,578	328,104,956	4,332,596,274	5,729,580,934	5,151,131,860	156,705,005	12,238,649	0.02735	0.03042	0.02835	0.0365	0.02786	-0.06133	0.02372	0.01422
v3	+0.006%	+0.196%	-0.028%	-0.046%	-0.052%	+0.074%	+0.12%	+0.12%	+0.126%	+0.096%	-0.693%	+0.07%	+1.426%	+0.08%	-1.099%
	398,802,546	328,812,813	4,331,074,972	5,725,949,358	5,147,429,760	156,868,070	12,239,879	0.0274	0.03048	0.02839	0.03617	0.0279	-0.06205	0.02375	0.01402
v4	-0.072%	+0.228%	-0.054%	-0.067%	-0.075%	-0.034%	-0.083%	+0.033%	+0.041%	+0.02%	-0.368%	-0.025%	+1.078%	+0.034%	-0.815%
	398,490,827	328,917,752	4,329,970,410	5,724,746,258	5,146,277,744	156,698,356	12,215,094	0.02737	0.03045	0.02836	0.03629	0.02787	-0.06184	0.02374	0.01406

5<app_convert数量≤20深度分析无显著性计算 | 计算工具

实验分组	cost	广告主价值	冷启动boost	send	show	click	convert	CTR1	CTR2	平均ectr	ectr_diff校 准	平均 recall_ctr	recall_ctr_diff 校准	平均 sati_ctr	sati_ctr_diff 校准
v1 对照组	178,091,804	162,264,221	2,368,288,359	3,812,902,167	3,342,813,408	101,745,902	8,584,649	0.02668	0.03044	0.02742	0.02741	0.05252	0.89357	0.02451	0.01091
v2 对照组	-0.024%	-0.103%	+0.025%	+0.035%	+0.035%	-0.005%	+0.107%	-0.041%	-0.04%	-0.03%	+0.399%	+0.007%	+0.108%	-0.041%	+0.174%
	178,049,351	162,097,898	2,368,874,317	3,814,250,403	3,343,980,429	101,740,408	8,593,863	0.02667	0.03042	0.02741	0.02752	0.05252	0.89453	0.0245	0.01093
v3	-0%	-0.026%	-0.02%	-0.031%	-0.041%	+0.064%	+0.081%	+0.095%	+0.105%	+0.074%	-0.806%	-0.003%	-0.231%	+0.065%	-2.749%
	178,091,029	162,222,811	2,367,818,730	3,811,726,292	3,341,449,859	101,811,330	8,591,603	0.02671	0.03047	0.02744	0.02719	0.05252	0.8915	0.02453	0.01061
v4	-0.028%	+0.037%	-0.048%	-0.049%	-0.055%	-0.01%	+0.037%	+0.038%	+0.044%	+0.016%	-0.843%	-0.011%	-0.125%	+0.01%	-2.938%
	178,042,522	162,323,838	2,367,143,388	3,811,045,863	3,340,991,265	101,735,304	8,587,850	0.02669	0.03045	0.02742	0.02718	0.05251	0.89245	0.02452	0.01059

20<app_convert数量<50深度分析无显著性计算 | 计算工具

实验分组	cost	广告主价值	冷启动boost	send	show	click	convert	CTR1	CTR2	平均ectr	ectr_diff校 准	平均 recall_ctr	recall_ctr_diff 校准	平均 sati_ctr	sati_ctr_diff 校准
v1 对照组	87,168,032	82,001,153	38,575,775	2,054,636,859	1,814,854,880	56,213,004	6,879,476	0.02736	0.03097	0.02842	0.03891	0.0532	0.86265	0.02542	0.01822
v2 对照组	-0.007%	-0.097%	+0.109%	+0.038%	+0.04%	-0.001%	+0.19%	-0.039%	-0.041%	-0.019%	+0.527%	+0.001%	+0.122%	-0.034%	+0.854%
	87,161,872	81,921,873	38,617,666	2,055,415,543	1,815,577,939	56,212,195	6,892,517	0.02735	0.03096	0.02842	0.03912	0.0532	0.8637	0.02541	0.01837
v3	-0.011%	-0.168%	+0.07%	-0.036%	-0.042%	+0.06%	+0.209%	+0.096%	+0.103%	+0.077%	-0.523%	-0.001%	-0.236%	+0.064%	-1.178%
	87,158,258	81,863,040	38,602,887	2,053,902,581	1,814,085,282	56,246,775	6,893,883	0.02739	0.03101	0.02844	0.03871	0.0532	0.86062	0.02543	0.018
v4	-0.038%	-0.06%	-0.001%	-0.063%	-0.069%	-0.027%	+0.128%	+0.037%	+0.042%	+0.022%	-0.407%	+0.004%	-0.101%	+0.012%	-0.878%
	87,134,901	81,951,773	38,575,311	2,053,332,827	1,813,596,734	56,197,894	6,888,265	0.02737	0.03099	0.02843	0.03875	0.0532	0.86178	0.02542	0.01806

掉量爆量

波动持平

账户掉量率深度分析无显著性计算

账户掉量率需要正确设置【日期】、【last_cost_level】等筛选项才能观看有效数据，设置方法详见参考链接

实验分组	掉量超过50%账户数	掉量观测范围账户数	掉量超50%账户占比
v1 对照组	1,305,032	5,696,458	22.91%
v2 对照组	-0.1% 1,303,729	-0.077% 5,692,084	-0.023% 22.904%
v3	+0.056% 1,305,765	-0.01% 5,695,879	+0.066% 22.925%
v4	-0.071% 1,304,105	-0.038% 5,694,318	-0.033% 22.902%

计划爆量率深度分析无显著性计算数据回溯

稳定性指标需要正确设置【日期】、【pricing_type】、【last_cost_level】等筛选项才能观看有

实验分组	爆量计划数	爆量观测范围计划数	爆量计划占比
v1 对照组	593,098	2,724,033	0.21773
v2 对照组	+0.029% 593,272	-0.081% 2,721,838	+0.11% 0.21797
v3	+0.028% 593,262	-0.018% 2,723,538	+0.046% 0.21783
v4	-0.16% 592,150	-0.125% 2,720,621	-0.035% 0.21765

推荐指标

CUPED-活跃天数-回到app(新)-20210901后开启实验可看从头累计数据产出助手

实验分组 拆分	累计用户数	人均活跃天数	近30天人均活跃天数	近14天人均活跃天数(2022.10....)	近1天人均活跃天数(辅助判断)
合并组1 对照组 v1+v2	179,103,916	8.29376	8.29376	8.29376	0.699392
合并组2 v3+v4	-0.0161% 无显著性检验 179,075,003	+0.006% ±0.005% 8.29426	+0.006% ±0.005% 8.29426	+0.006% ±0.005% 8.29426	+0.0094% ±0.01% 0.699458

CUPED-核心指标(新)-20210901后开启的实验可用从头累计数据产出助手

实验分组 拆分	User	StayDuration/U	Publish/U	Play/U	人均Sessions个数	PlayTime/U	Finish/U
合并组1 对照组 v1+v2	179,103,916	66,057.306	1.06879	2,469.82	130.815	49,733,989.421	460.701
合并组2 v3+v4	-0.0161% 无显著性检验 179,075,003	+0.0053% ±0.011% 66,060.79	-0.0122% ±0.044% 1.06866	+0.0008% ±0.014% 2,469.84	+0.0023% ±0.012% 130.818	+0.0085% ±0.012% 49,738,216.315	+0.0054% ±0.013% 460.726

团队合作

- 中国商业产品与技术-端变现技术-抖音变现-原生与创新业务： 张杰 黄波 吴健 萧赫
- 中国商业产品与技术-端变现技术-GIP变现： 陈垚鑫 余鑫 江伟 陈云博
- 中国商业产品与技术-Ads Core技术-Applied Tech： 林炜 周继臣 孙祥
- 中国商业产品与技术-商业平台与架构-Ads Infra-端变现平台： 宋姝雨 聂俊豪